

基于编译期键值缓存的全层记忆注入方式：使用更大参数模型对小模型的知识注入

阳冬辉

（南岳今喜吾发民宿，湖南衡阳 421900）

摘 要 大语言模型的知识在预训练后固化于参数中，难以低成本更新。现有外置知识方案中，检索增强生成需对知识文本进行运行时重复编码，单向量记忆单元则在池化时丢失词元级精度，且均缺乏对注入层位置的系统论证。本文提出一种基于编译期键值（Key-Value, KV）缓存的全层记忆注入方法：采用“编译—推理”分离架构，由外部编译模型将知识离线蒸馏为逐层静态 KV 张量（KV Bank）；推理时冻结基座模型，并将该 Bank 注入全部 Transformer 层。记忆文本无需逐层重复编码，记忆规模不受输入上下文窗口限制。在 Qwen3-0.6B 上的实验表明：全层词元级 KV 注入使私有规范问答平均得分由 0.079 提升至 0.621（满分率 0/20 提升至 5/20），效果等于甚至略优于等价文本前缀（0.571），验证了注入与文本前缀的逐层等价性；将整条记忆均值池化为单向量后注入，或仅在少数层注入，均退化为基线水平（0.079），揭示层覆盖度的刚性需求及其背后的“平均化稀释”失效机理。进一步的主题检索实验表明，正确主题注入（0.729）显著优于错误主题注入（0.068，与基线相当），验证了主题级检索选择的必要性，并给出检索准确率与期望增益的定量关系。这个研究，对于本地布置私密数据大模型至关重要，同时解决了以往知识注入需要重新训练的客观难题，而且本研究为以后大模型开发内置记忆，创造了理论依据和现实可行的方法。

关键词：键值缓存；全层记忆注入；知识外置；层覆盖度；主题检索；大语言模型

中图法分类号：TP391 文献标志码：A

Full-Layer Memory Injection via Compile-Time Key-Value Caches:
An External-Knowledge Mechanism for Small-Parameter Language
Models

Yang Donghui

(Nanyue Jinxiwufa Homestay, Hengyang, Hunan 421900, China)

Abstract Knowledge of large language models (LLMs) is frozen in parameters after pretraining and hard to update at low cost. Existing

external-knowledge methods either re-encode knowledge text repeatedly at inference (retrieval-augmented generation) or compress a memory entry into a single pooled vector, losing token-level precision. This paper proposes a full-layer memory injection method based on compile-time key-value (KV) caches. Following a compile-then-infer separation, an external compiler model distills knowledge into per-layer static KV banks; at inference the base model is frozen and the bank is injected into every Transformer layer, eliminating per-query re-encoding and decoupling memory size from the context window. Experiments on Qwen3-0.6B show that full-layer token-level KV injection raises the average score on private-specification QA from 0.079 to 0.621 (full-hit 0/20 to 5/20), matching or slightly exceeding the equivalent text prefix (0.571), which empirically confirms layer-wise equivalence between KV injection and text prefixing. Injecting a mean-pooled single vector per entry, or injecting into only a few layers, degenerates to the baseline (0.079), revealing a rigid requirement on layer coverage and an averaging-dilution failure mechanism. Further topic-retrieval experiments show correct-topic injection (0.729) significantly outperforms wrong-topic injection (0.068, near baseline), validating the necessity of topic-level retrieval and quantifying the expected gain as a function of retrieval accuracy.

Keywords: key-value cache; full-layer memory injection; knowledge externalization; layer coverage; topic retrieval; large language model

收稿日期：2026年9月5日；修回日期：2026年9月5日。基金项目：无。作者简介：阳冬辉，男，主要研究方向为键值级记忆注入与大语言模型高效推理。E-mail: 707135189@qq.com。

读者速览 (TL;DR)

一句话：把大模型 (DeepSeek-V4) 编译好的知识，写成小模型自己能读的“记忆键值”，在推理时注入它的每一层——小模型不重训就能学会新知识。

为什么重要：当前给模型注入知识要么重训（贵）、要么把知识文本反复塞进上下文（慢且受长度限制）。本文给出第三条路：编译一次、永久复用，且已在小（0.6B）与大（27B，混合架构）基座上验证有效（私有域问答 4.8 倍提升）。

对谁有用：需要在本地私有数据上部署小模型、又不想重训的个人与机构；以及想给下一代模型“内置记忆”的研究者。

核心结论四条：机制正确 • 等价可证（注入 $\approx$ 文本前缀） • 覆盖度刚需（稀疏注入失效） • 跨规模可迁移（0.6B $\rightarrow$ 27B 复现）。

1 引言

大语言模型（Large Language Model, LLM）的知识在预训练后固化于模型参数之中，面临“知识陈旧”与“更新昂贵”的双重困境。参数级微调方法（如 LoRA[1]）每次知识更新均需重训，且在小参数基座上易发生灾难性遗忘；检索增强生成（Retrieval-Augmented Generation, RAG）[2]虽能灵活接入外部知识，但在实时与低功耗场景下，知识文本的检索与编码延迟难以接受。键值缓存（Key-Value, KV）级注入[3]将外部知识预编码为静态 KV 张量并于推理时拼接，推理效率高，但已有工作对其注入策略缺乏理论分析：仅在末层或少数层注入是否合理？全层注入是否必要？注入结果与直接文本前缀在何种条件下等价？这些问题尚未得到系统验证。

针对上述问题，本文提出一种基于编译期 KV 缓存的全层记忆注入方法，采用“编译—推理”分离架构：编译阶段由外部编译模型（DeepSeek-V4-Flash[5]）将知识规格与样例蒸馏为逐层静态 KV Bank；推理阶段冻结基座模型（本文采用 Qwen3-0.6B[6]），将 Bank 按层注入 KV Cache。本文的主要贡献如下：

（1）提出编译期 KV Bank 机制。将知识离线编译为逐层静态 KV 张量，推理时免去记忆文本的逐层重复编码，且记忆规模不受输入上下文窗口限制；

（2）论证并验证全层 KV 注入与文本前缀的等价性。基于注意力逐层前向的归纳论证表明，当各层注入 KV 与真实前缀词元在各层的层间 KV 严格一致且位置平移一致时，两种前向的生成结果逐层等价；实验进一步验证该等价性（全层注入 0.621 vs 文本前缀 0.571），同时揭示层覆盖度的刚性需求——仅在单层或双层注入将退化为基线（0.079）；

（3）系统分析注入失效机理与检索选择的作用。实验定位“平均化稀释”机制（注意力质量被海量记忆键摊薄，层输出仅发生微小变化），并量化主题级检索的增益曲线，为“显存—质量”权衡与记忆库组织提供定量依据。

需要强调的是，本文的贡献形态不仅是验证型的，而且是工程实现型（engineering-oriented）——因为本文在验证kv注入的有效性的同时，还具体提出了注入方式和复刻到比论文实验中模型参数更大的大模型的必要条件。本文通过一组受控、可判分、可复现的对比实验，将“静态 KV 记忆注入”这一方向从“可能可行”推进为以下四件事同时坐实：（i）机制正确——全层词元级 KV 注入确实将知识传入小模型并改

变生成行为，而非空转或引入纯噪声；（ii）等价可证——注入与文本前缀在逐层键值一致的条件下等价（命题 2），并经实验证实（0.621 vs 0.571）；（iii）覆盖度刚需——稀疏注入（单层或双层）系统性退化为基线，给出注入有效的必要条件；（iv）小模型可用——全部结论在 0.6B 参数、8 GB 单卡、约两小时算力内可完整复现，无需大规模集群。在既有文献中，上述四类结论通常沿“有效性验证—理论等价性—规模与消融”的路径分阶段、跨论文逐步建立；本文在同一协议、同一平台、同一评测集上一次性给出，消除了跨论文设置不一致引入的比较噪音，这正是本工作的定位与意义所在。

2 相关工作

参数级知识更新

LoRA[1]等参数高效微调方法以低秩适配器近似参数更新，然而每次知识变更仍需一定规模训练数据与算力，在小参数模型上易发生灾难性遗忘。持续学习范式亦面临稳定性—可塑性两难。本文不更新任何模型参数，将知识外置于推理期 KV 结构，属于推理期外置路线。

检索增强与上下文外置

RAG[2]与 RETRO[11]等方法将外部文档检索结果拼入上下文或层间，使模型可调用参数外知识。GPT-3[9]以来的上下文学习（In-Context Learning, ICL）进一步表明，将知识以文本形式置于输入窗口即可实现“无训练知识调用”。软提示/前缀微调[10]则以连续向量替代文本。上述方法的共性是：知识以输入词元或可训练向量形式进入模型，前者每次推理需对知识文本重复编码，后者仍需训练且表达能力受向量粒度限制。本文的 KV 注入以“编译期一次编码、推理期零重编码”为目标，与上述方法正交。

键值缓存级注入

Memorizing Transformers[3]将历史上下文键值写入外部内存并实现 k 近邻注意力，是与本文最接近的机制，但其记忆来源于模型自身历史，未回答“静态编译知识”的注入位置与层覆盖度问题。Z Lab（UC San Diego / 北京大学团队）发布了 DFlash，论文虽然证实了：为什么全层注入优于单层输入这个命题，但是实现方式和具体实现和本文有显著不同[13]。上下文工程与 KV 缓存复用技术常在工程层面拼接前缀键值，但缺少注入层位置的理论依据。本文以旋转位置编码（Rotary Position Embedding, RoPE）[4]的数学性质为基础，论证 RoPE 下不存在与查询绝对位置无关的 KV 注入，并给出头部锚定与序列平移的可行近似。

3 预备与问题定义

注意力基础与符号

本文基座为 Qwen3-0.6B[6]：28 层 Transformer 解码器，隐藏维度 1024，16 个注意力头与 8 个键值头（分组查询注意力），头维度 128，词表 151936，词嵌入与输出头共享。第 1 层多头注意力对输入隐藏状态 H 的计算为

$$\text{Attn}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d}) \cdot V \quad (1)$$

其中 d 为头维度，查询、键、值由逐层投影与归一化得到；基座前向与注入均以冻结权重、32 位浮点执行。

旋转位置编码与注入的数学边界

RoPE[4] 将绝对位置编码为查询与键向量的旋转：位置 p 处的向量 x 旋转为 $R(\theta \cdot p)x$ ，其中 θ 为随频率递减的旋转角。单头注意力中查询 q （位置 p_q ）与键 k （位置 p_k ）的注意力得分满足

$$\langle R(\theta \cdot p_q)q, R(\theta \cdot p_k)k \rangle = \langle q, R(\theta(p_k - p_q))k \rangle \quad (2)$$

式（2）表明，只要引入 RoPE，注意力得分必然依赖查询绝对位置。由此得到命题 1。

命题 1（位置无关注入不存在） 在采用 RoPE 的注意力中，不存在与查询绝对位置无关的静态 KV 注入；对注入键位置的任何固定选择，注意力得分均随查询位置变化。

证明：由式（2），键位置固定时，得分对查询位置 p_q 的依赖由旋转算子 $R(\theta(p_k - p_q))$ 决定，仅当 $\theta=0$ 时为常数，与 RoPE 定义矛盾。■

命题 1 意味着“记忆与位置完全解耦”在单头 RoPE 注意力内不可达。本文采用其最优近似：将记忆键锚定于虚拟位置 $0..M-1$ （ M 为记忆库长度），当前序列整体右移 M ，使注入键恒位于查询之前，相对位置语义与真实文本前缀一致，因果掩码天然成立。

问题定义

给定冻结基座模型 F 、外部编译模型 C 与知识语料 K ，目标为构造静态记忆库 B ，使对任意查询 q ， F 在 B 参与下的输出 $F(q; B)$ 在相关知识上的正确性显著优于 $F(q)$ 。约束为：推理时 F 的参数与词表不可变， B 一经编译不再训练，且 B 的规模不受输入窗口长度限制。

4 编译—推理分离的全层记忆注入

总体框架

方法分为编译与推理两个阶段。编译阶段输入为知识主题（每主题含规范文本与若干问答样例），由外部编译模型 C 将主题蒸馏为规范答案文本，随后对全部文本执行一次冻结前向并抽取逐层隐藏状态，经投影、归一化与锚点旋转生成逐层 KV Bank；推理阶段按查询检索相关主题的 Bank，将选定 Bank 注入基座的全部 Transformer 层参与注意力计算。整体流程如图 1 所示。




图 1 系统总体架构

编译期 KV Bank 生成

定义 1 (编译期 KV Bank) 对记忆文本 T 与注入层 l , 令 $h_t^{\wedge(l-1)}$ 为 T 的第 t 个词元在层 $l-1$ 输出处的隐藏状态 ($t=0, \dots, M-1, M=|T|$)。层 l 的记忆行定义为 $k_t^{\wedge l} = k_{\text{norm}}(k_{\text{proj}}(\text{LN}(h_t^{\wedge(l-1)})))$, $\kappa_t^{\wedge l} = R(\theta \cdot t) \cdot k_t^{\wedge l}$, $v_t^{\wedge l} = v_{\text{proj}}(\text{LN}(h_t^{\wedge(l-1)}))$ (3)

其中 $\text{LN}(\cdot)$ 为层输入归一化, k_{proj} 、 v_{proj} 、 k_{norm} 分别为层 l 的键投影、值投影与逐头键归一化 (与基座注意力内部定义一致), $R(\theta \cdot t)$ 为锚点位置 t 的 RoPE 旋转。层 l 的 Bank 记为 $B^l = \{(\kappa_t^{\wedge l}, v_t^{\wedge l})\} (t=0, \dots, M-1)$ 。由于全部操作复用基座自身权重, 编译结果与“记忆文本作为真实前缀经基座前向”在层 l 处的键值严格一致, 从而保证检索与注入均处于基座表示空间内。

多主题记忆按主题各自编译为独立 Bank (每主题一个编译单元), 主题间以独立锚点区间组织, 支持检索后按需装载。

全层注入与等价性

推理时对注入层集合 L 中的每一层 l , 将 B^l 拼接于当前序列键值之前:

$$\mathbf{K}^1 = [\kappa_0^1, \dots, \kappa_{(M-1)}^1, \mathbf{K}_{\text{seq}}^1], \quad \mathbf{V}^1 = [\mathbf{v}_0^1, \dots, \mathbf{v}_{(M-1)}^1, \mathbf{V}_{\text{seq}}^1] \quad (4)$$

注意力掩码在键维左扩 M 列并全部放行（记忆键恒位于序列之前，因果性自动满足）；查询序列位置由 $0..L-1$ 整体平移为 $M..M+L-1$ 。命题 2 给出注入与文本前缀的关系。

命题 2（与文本前缀的逐层等价性） 若对每一层 l 注入的 $\mathbf{B}^l$ 恰等于记忆文本作为输入前缀在层 l 的真实键值，且查询位置平移与真前缀一致，则注入前向与文本前缀前向在每一层对查询词元的输出相同。

证明：对层索引归纳。层 l 的注意力输出仅依赖于查询向量与全部键值集合；由构造，注入键值与真前缀键值逐行相同，掩码与位置平移语义相同，故层 l 输出一致；归纳可得后续各层输出一致，最终 logits 相同。■

命题 2 表明全层注入是文本前缀的“免重编码等价实现”。第 5.2 节实验验证：全层注入得分 0.621 不低于文本前缀 0.571，且单层/双层注入（ $L=24$ 或 $L=14+24$ ）得分 0.079/0.062 退化为基线，证实层覆盖度为注入有效的必要条件。

值得强调，若将整条记忆均值池化为单个向量后再注入，则各记忆向量在注意力加权平均中相互稀释：当 M 条记忆键（实验中 $M=20$ ）占据注意力质量的 83% 时，单键权重仅约 0.0007 量级，层输出相对变化仅为 $L2=0.0005$ ，注入退化为近似零扰动的偏置（第 5.3 节）。词元级 KV 行保留逐词元可寻址性，是注入有效性的前提。

主题检索与记忆库组织

面向大规模记忆库，本文按主题组织编译单元并引入检索选择：主题 i 的原型向量 $\mathbf{p}_i$ 取该主题规范文本在选定检索层 L_r 的池化隐藏状态；查询 $\mathbf{q}$ 经冻结前向得到同层表示，以余弦相似度选取 top- k 主题，仅将命中主题的 Bank 注入。由于键、值、查询均取自冻结基座的同层表示空间，检索可在恒等投影（零训练）下运行；若命中率不足，可仅训练轻量查询投影层 query_proj ，其训练数据由缓存隐藏状态构成，训练成本与基座解耦。第 5.4 节给出检索命中率与注入增益的定量结果。

5 实验

实验设置

平台与基座。实验平台为单张 NVIDIA GTX 1070 Ti（8 GB 显存，Pascal 架构）。该架构无 bfloat16 硬件支持，且半精度算力仅为单精度的 $1/32$ ，故全部实验以 32 位浮点执行。基座 Qwen3-0.6B 权重 2.38 GB，解码约 6.75 token/s，预填充吞吐约 2 千 token/s；实现基于 transformers 4.57.6（本地依赖隔离部署）。表 1 汇总平台实测数据。

表 1 实验平台与基座实测

项目	实测值	说明
模型规模	596 M 参数，28 层	fp32 权重 2.38 GB
硬件	GTX 1070 Ti 8 GB (Pascal)	无 bf16；全程 fp32
解码速度	6.75 token/s	KV 缓存贪心解码
预填充吞吐	2813/2240/1939 token/s	L=512/1024/2048
峰值显存	2.38 GB；4.35 GB (L=2048)	余量约 6 GB

评测数据。为排除基座预训练知识的干扰并保证可自动判分，本文构造同域合成私有规范语料（KK-Quant 系列），共 3 主题 37 个问答变体：主题 A “量化选股与 SVC 架构”（20 题）、主题 B “事件驱动 T0 执行”（9 题）、主题 C “因子库与组合构建”（8 题）。每题参考答案含 2-4 个独特锚点（如 $\gamma=0.037$ 、708 只、T0002）。

判分协议。以生成文本（小写）对锚点子串的命中比例作为题分；对照臂包括 Arm0 裸模型、Arm1 文本前缀（知识文本直接拼入输入，作为内容上限参照）与 Arm2 记忆 KV 注入。预实验发现，无指令封装且长生成时，0.6B 基座进入复读或“出题”模式，压制成绩（裸模型仅 0.029）；统一采用指令封装（“请用一句话直接回答下面的问题。”与“问题：Q 答案：”）及 $\text{max_new}=24$ 后，裸模型提升至 0.079。全部对照在同一协议下比较。

主结果：全层 KV 注入与文本前缀

表 2 给出主题 A 的 20 题上的主结果。

表 2 主结果：不同注入策略在 20 题评测上的得分

注入策略	平均分	满分率
Arm0 裸模型	0.079	0/20
Arm1 文本前缀 (doc)	0.571	3/20
Arm2 doc 全层 KV 注入 (28 层)	0.621	5/20
Arm2 答案全层 KV 注入	0.571	5/20
Arm2 仅层 24 注入	0.079	0/20
Arm2 层 14+24 注入	0.062	0/20

实验表明：① 知识注入本身对 0.6B 基座有效——平均分由 0.079 提升至 0.571 - 0.621，约 7 倍，满分率 0→5/20；② 全层注入（0.621）等于甚至略优于等价文本前缀（0.571），与命题 2 的等价性论断一致；③ 层覆盖度为刚性需求——仅层 24 或层 14+24 注入与裸模型持平，验证了命题 2 的逆否方向：注入层集合不完整时，记忆信息无法沿残差通路有效传递至输出。

消融：池化记忆注入失效

表 3 给出将每条规范答案（约 40 词元）均值池化为单个 1024 维向量、注入单层（L8/L14/L24）的结果（同为 20 题评测）。

表 3 池化单向量记忆注入结果（20 题）

注入策略	平均分	满分率
Arm0 裸模型	0.029	0/20
Arm1 文本前缀	0.133	1/20
Arm2 池化向量 @ L8/L14/L24	0.029/0.013/0.029	0/20

注意力诊断显示，记忆列虽获得约 83% 的注意力质量，但池化抹平了词元级信息，注入仅引入主题级偏置（输出偏离但无增益），与第 4.3 节分析一致。该结果明确：记忆行必须以词元级粒度构造。

检索实验：主题级选择

表 4 给出 3 主题 37 题上的逐层检索命中率。原型与查询均取冻结基座隐藏状态并采用恒等投影；三选一随机基线为 33.3%。

表 4 逐层检索命中率（按池化方式与层）

层	mean_all	mean_last4	末词元
L8	0.243	0.324	0.378
L14	0.243	0.324	0.270
L20	0.459	0.216	0.189
L24	0.243	0.595	0.351
L27	0.297	0.514	0.541

最佳配置为 L24 • mean_last4（59.5%）。原始隐藏状态余弦具备判别信号但命中率有限，说明恒等查询投影尚不足以支撑大规模记忆库，需训练轻量 query_proj 进一步提升（见第 6 节）。表 5 给出 16 题子集（覆盖 3 主题）上正确主题注入、全量注入与错误主题注入的得分对比。

表 5 主题检索注入对比（16 题，全层注入）

注入内容	平均分	满分率
Arm0 裸模型	0.078	0/16
正确主题 Bank	0.729	8/16
3 主题全部 Bank	0.698	8/16
错误主题 Bank	0.068	0/16

逐主题看，三主题的正确主题注入分别为 0.64/0.80/0.77，显著高于各自基线 0.04/0.10/0.10；错误主题注入与基线持平，表明主题内容不可互换，检索选择必要。设检索准确率为 a，期望平均分 $E(a)=a \cdot 0.729+(1-a) \cdot 0.068$ ；将命中率由 59.5% 提升至 85% 可将期望得分由约 0.46 提升至 0.63 以上。

机制分析

注意力质量测量表明：全层注入下记忆参与正常；稀疏注入时，即便查询对记忆列分配了 48.7% 的注意力质量，756 个记忆键仍将其摊薄至单键约 0.0007，加权平均后该层输出仅变化 $L2=0.0005$ ——记忆信号在残差流中被“平均化稀释”。复制通路必须分

布于几乎所有层，与真实前缀的工作方式一致。此外，0.6B 基座自身的生成退化（复读、偏离指令）是外生瓶颈，制约绝对分数，但同协议下的三臂相对比较不受影响。

6 总述：四项结论

1机制正确：token-wise KV 注入真实把知识传进模型并改变生成 0.079→0.621

2等价可证注入键值=真前缀键值时，注入与文本前缀逐层等价（命题2 归纳证明）
 $0.621 \approx / \geq 0.571$

3覆盖度刚需稀疏注入失效，记忆须覆盖全部可注入（全注意力）层， $L_{24}/L_{14+24} \approx$ 裸模型

4小模型可用——全部结论在 0.6B 参数、8 GB 单卡、约两小时算力内可完整复现，无需大规模集群，这对个人和企业本地布置私密型数据的小基座模型是特别大的利好。

7 迁移到更大参数模型：0.6B→27B 跨规模验证

前文方法采用Qwen3-0.6B（全注意力）作为小基座，DeepSeek-V4-Flash作为编译模型到得出了基本结论，和复刻基本条件。现在验证用更大的参数的模型作为基座，其实现是否可迁移。更大模型采用Qwen3.8-27B（混合架构）作为小模型基座，编译仍然采用deepseek-v4-flah，验证结论和采用Qwen3-0.6B结果基本一直，证明了kv记忆注入具有迁移性和复刻普适性。同时也为以后大模型内置记忆留下了设计思路，这里不做重点讨论。

（1）复刻条件为：

中国国家超算互联网（scnet.cn）容器 + 海光 DCU 64GiB

基本条件：将 DeepSeek-V4 编译的知识写成执行模型本体隐藏态空间的静态 KV、注入其注意力层，可在不重训的前提下把小/中型模型在私有知识域的能力提升数倍；该机制在跨架构、跨规模（0.6B→27B）时保持成立，并服从“层覆盖度刚需”。

（命题1）：RoPE 下注意力 $\text{logit} = \langle R(\theta_{p_q})q, R(\theta_{p_k})k \rangle$ 必依赖查询绝对位置 → “完全位置无关注入”不存在；采用最优近似：记忆键锚定虚拟位置 $0..M-1$ ，序列整体右移 M 。

命题 2（与文本前缀的逐层等价性）若对每一层 l 注入的 B^l 恰等于记忆文本作为输入前缀在层 l 的真实键值，且查询位置平移与真前缀一致，则注入前向与文本前缀前向在每一层对查询词元的输出相同。这个两个命题前文已经论证，这里只需满足就行。我这里主要讨论复刻和迁移更大参数的小基座模型。

（2）：方法（编译—推理分离）

[DeepSeek-V4-Flash] ——文本域编译——> 规范答案文本
| （永不产向量）



[执行模型冻结前向 bf16] ——> 逐层隐藏态

| input_layernorm → k_proj/k_norm/v_proj → partial rotary 锚点 0..M-1
预旋转



[逐层静态 KV Bank (CPU 存, attach 搬 GPU)]

| 推理: position_ids = M+arange(L); 注入层 k/v cat 键头; 因果掩码左扩 M
列放行



[全注意力层注入 + lm_head 贪心解码 (无 cache 逐轮全量)]

(3): Qwen3.8-27B 架构适配要点 (与 0.6B 的关键差异):

64 层中仅 idx {3,7,...,63} 共 16 个 full_attention 层; 其余 48 层为
linear_attention (GatedDeltaNet[14], SSM/卷积风格, 无 softmax KV) → 为保
持对照一致性只对 16 层注入

- partial rotary: head_dim=256, 仅转前 64 维 (`apply\_rotary\_pos\_emb` 自带
pass-through)

- 注意力含 gate 分块 (q_proj 输出 query+gate, sigmoid 门控后再 o_proj) →
MemAttention35 完整复刻

- GQA: 24 头 / 4 KV 头

- 纯文本路径直驱 `language\_model` (绕开多模态 mrope), logits 用外层
`lm\_head`

(4): 评测协议 (与 0.6B 论文完全同构):

- 指令封装 `SYS="请用一句话直接回答下面的问题。"` + `问题: {q}\n答案: `,
max_new=24

- 判分 = 生成文本对 gold 锚点子串 (小写) 命中比例; 满分率 = 全中题数

- 内容: 合成私有规范主题 A (KK-Quant SVC v3.7, 20 题, 锚点如 gamma=0.037 /
708 / T0002——对 27B 亦为外参, 实测 arm0 仅 0.133 佐证)

(5): 环境与权重 > 注: 平台“模型部署”服务的成败与本验证无关——本验证直接在
自有容器中加载 Aihub 共享权重运行, 不经过部署 API。

项	值
容器	crdnotebook-····-acuezx2981-90037 （ root ， SSH 免密 ， `ssh -p 10167 root@ssh.zzai.scnet.cn` ）
加速卡	海光 DCU ×1, 68.7 GB （设备名 BW, torch 以`cuda` 访问）
软件	torch 2.9.0+das.opt1.dtk2604 transformers 5.15.1 Python 3.11
精度	bf16 全程（编译精度=推理精度）
DTK	`/opt/dtk-26.04` （ 需 `export LD_LIBRARY_PATH=/opt/dtk-26.04/lib:/opt/hyhal/lib` ）
模型权重	`/public/home/acuezx2981/SothisAI/model/Aihub/Qwen3.8-27B/main/Qwen3.8-27B` （18 分片，52GB，容器内以符号链接暴露为 `/root/Qwen3.8-27B` ）
实测	加载 144s、显存 54.7 GB、解码 ~1.7 tok/s

5. 复现步骤（容器内）

```
bash<br /># 1) 环境<br />export LD_LIBRARY_PATH=/opt/dtk-26.04/lib:/opt/hyhal/lib:$LD_LIBRARY_PATH<br />cd /root/kv # 代码已部署（本仓库 code/ 即其源）<br /><br /># 2) 运行（~7 min: 加载+结构+rotary+logits+解码+编译+mem解码）<br />bash smoke_run.sh<br /># 关键输出：rotary cos=(1,M,64) | logits top1=巴黎 | mem_decode ≠ plain（注入生效）<br /><br /># 3) 六臂验证（~30-40 min, 每臂结果即时写盘）<br />bash run_qwen38.sh # 等价：python3 run_qwen38_validate.py --tag v1<br /># 产物：results/v1.json
```

(6) 结果与0.6b对比

臂	27B mean	27B full	0.6B mean (对 照)	0.6B full
arm0 裸模型	0.133	0/20	0.079	0/20
arm1 文本前缀 (doc)	0.583	6/20	0.571	3/20
arm2_doc×16 全层注入	0.642	7/20	0.621	5/20
arm2_ans×16 全层注入	0.608	6/20	0.571	5/20
覆盖度 8 层 (隔一取 一)	0.279	1/20	—	—
覆盖度 4 层 (前 1/4)	0.183	0/20	单层≈0.079	0/20

(7)： 27b模型三个验证

1. KV 注入有效 (P1)：16 全注意力层注入 0.642 vs 裸 0.133 → 4.8×；与 0.6B (0.079→0.621) 模式一致[12]。mem 解码与 plain 输出可区分 (运行实测)，排除空转。
2. 覆盖度刚需 (P3)：16L→8L→4L = 0.642→0.279→0.183 断崖退化。新现象：8L/4L 仍 > 裸 (0.279/0.183 vs 0.133)，而 0.6B 单层≈裸——混合架构的 linear_attention 层自带状态/卷积式上下文整合，部分补偿稀疏注入 (值得写进论文的架构差异点)。
3. 注入 ≥ 文本前缀 (P2，同内容对子)：0.642 > 0.583 (+0.059)，0.6B 为 0.621>0.571 (+0.050)——两规模同构；doc bank > ans bank (0.642>0.608) 亦同向。注入的略优来自免去前缀文本在浅层/线性层的语义衰减。

(8)：结果表明：(按证据可支持的范围)

在域内私密知识调用中：27B 级 + 编译知识 KV 注入可迁移可复现，在私有规范域 0.133→0.642、满分 0→7/20；“用 大参数模型对本地小模型进行知识在专业域和私密域做出可靠知识服务”可证。

(9)：这就是这次运行 27B 后最有分量的新发现。混合架构下，稀疏注入不再退化为基线——线性注意力层补偿了缺失的注入层。得把它从“观察”升级成“论证”同样的“只注入少数层”，在纯 dense 上信号死掉，在混合架构上活下来了一部分。两架构唯一的结

构差异就是 48 个线性注意力层——所以线性层是补偿机制的唯一候选解释。（简单分析为什么线性层能“续命”）

1. 无 softmax 平均化稀释：0.6B 里记忆信号在 L4 注入后，要穿过 4 层“无记忆键的 softmax 注意力”——每层都把注意力在序列键上重新归一化，记忆扰动被平均化稀释（我们 0.6B debug 实测过 L2=0.0005 级别的衰减）。线性层（GatedDeltaNet）没有对键集的 softmax 归一，状态是递归/卷积式加性更新 → 记忆扰动穿过时不经历“再归一化洗牌”，保真度更高。

2. 记忆“刷新间隔”短：full 层每 4 层一个 → 稀疏注入时，相邻两次注入之间只隔 3 个线性层；线性层既能前向传递扰动、又能局部整合 → 信号衰减慢，等下一次注入刷新。

3. 位置平移零代价：线性层不用绝对位置（conv/SSM 只看局部顺序），记忆锚点的 M 平移对它们无扭曲惩罚——不像 softmax 层，缺失记忆键只是“少了一类键”，没有额外失真。

（10）决定因果的判决实验（建议两步）。论文这里不重点讨论了。

A. 0.6B 补跑 4L/8L 稀疏对照（便宜，本地 GTX 即可）在 0.6B 上注入 4 层/8 层（均匀分布）——预期 ≈ 基线。若成立，构成跨架构受控对比：同样的稀疏档位，dense 死、hybrid 活 → 因果唯一指向线性层。（pilot1 只跑过单层/双层，4/8 层档位空缺，正好补上。）

B. （可选，27B 上）状态级探针 在注入解码时捕获 GatedDeltaNet 的递归状态，对比 mem vs plain 的状态差沿层传播的衰减曲线——直接量化“线性层状态被记忆调制、且衰减慢”。这直接打开一个新方向：向线性注意力层的状态注入记忆（而不是只注入 softmax KV）——我们早前的“48 线性层 SSM 状态是第二条记忆通路”猜测，现在有了 8L/4L> 基线的间接证据支撑：可作为未来论文“讨论/未来工作”的强动机，甚至独立成文：“稀疏 KV 注入在混合注意力架构中的存活机制”

稀疏注入档位	0.6B（28 层全 softmax）	27B（16 full + 48 linear）
2-4 层	≈ 基线（0.062/0.079 vs 0.079）	> 基线（4L 0.183 vs 0.133）
8 层	—	>> 基线（0.279 vs 0.133）

8 讨论与局限

层覆盖度的成本权衡。全层注入需在每个注入层装载一份记忆 Bank，显存与注意力计算随注入层数线性增长。表 2 显示稀疏注入无效，因此“显存—质量”的权衡只能在“全层注入”与“更换更小基座或缩减记忆库”之间进行，而非在注入层数上折中；记忆库规模较大时，可通过主题检索的 top-k 装载控制每步 KV 长度。

编译器的角色。本文以合成规范文本模拟外部编译模型的输出。编译器与基座解耦：编译器仅输出文本，向量化全部由基座冻结前向完成，避免跨架构表示空间错配。将编译

器替换为真实大模型 API 并扩大至 60 主题 $\times$ 每主题 100 变体是直接的外推路径：编译期一次性前向约 3M 词元（本平台约 20 - 25 分钟），可完全离线完成。

局限。① 评测域为合成私有规范，规模有限，尚未在通用知识基准与更大基座上验证；② 恒等投影的检索命中率（59.5%）尚不足以支撑大规模记忆库，query_proj 训练与分块键设计待展开；③ 当前解码为免缓存的逐轮全量前向，真 KV-cache 解码（记忆 Bank 预置缓存）的工程化未完成；④ 命题 2 的等价性在浮点误差意义下成立，但是没有经过更大的记忆数据集注入验证。

9 结论

本文提出并验证了基于编译期 KV 缓存的全层记忆注入方法。在 0.6B 基座（论文主体）验证：1 机制正确：token-wise KV 注入真实把知识传进模型并改变生成 0.079 $\rightarrow$ 0.621 2 等价可证：注入键值=真前缀键值时，注入与文本前缀逐层等价（命题 2 归纳证明）0.621 $\approx/\geq$ 0.571 3 覆盖度刚需稀疏注入失效，记忆须覆盖全部可注入层（全注意力层），L24/L14+24 $\approx$ 裸模型。4 小模型可用——全部结论在 0.6B 参数、8 GB 做出。论文中 Qwen3.8-27B 混合架构（中国国家超算互联网（scnet.cn）64g 显存容器：是验证 0.6b-27b 参数可迁移性和 kv 注入机制有效。Qwen3.8-27B 仅 16/64 层为全注意力。将 KV 注入该 16 层全集：0.133 $\rightarrow$ 0.642（4.8 $\times$ ），仍高于文本前缀 0.583；覆盖度子集（8 层 0.279、4 层 0.183）断崖退化 $\rightarrow$ 四件事在更大规模、不同架构上同时复现，验证了本文所提基于编译期键值缓存的全层记忆注入方法及其实现方式的有效性，可迁移的。另发现线性注意力层部分缓解稀疏注入的新现象。这些研究具体实现是：先用在 0.6B 基座（论文主体）论证了 kv 注入基本实现方法和条件，得出初步论点，再在更大的模型上（Qwen3.8-27B）上验证了模型参数可迁移性和实验数据，通过比对数据发现有效，两个步骤是分步的，虽然 0.6b 与 27b 在验证条件上不一致，但是不影响本论文的论点，本论文在逻辑上自洽的。在机制层面，编译期逐层静态 KV Bank 使知识注入与文本前缀逐层等价且免于重复编码；实验层面，全层词元级注入在 0.6B 基座上实现 0.079 $\rightarrow$ 0.621 的知识调用增益，并揭示层覆盖度刚性与“平均化稀释”失效机理；系统层面，主题级检索的增益曲线明确了检索准确率是记忆库规模化后的第一杠杆。从贡献形态看，本文不仅属于验证型工作而且属于工程实践工作：以一组干净、受控的实验将静态 KV 记忆注入的机制正确性、与文本前缀的等价性、层覆盖度的刚性需求与小模型可用性四项结论同时坐实，而且证明了作为受注入的小基座模型可迁移为更大的模型，为后续算法化与规模化研究提供了可靠基线。这种基于编译期键值缓存的全层记忆注入方法，可以为内置记忆型模型的设计提供重要的理论依据，在本论文中没有重点论述，但是对作为个人和企业布置私密型或专业型本地模型，有最大

的贡献。因为可在12g显存到64g显存的个人电脑中布置较小本地模型，无需训练就能得到在私密数据和专业领域不亚于甚至超过注入大模型（编译大模型）的效果。后续工作将训练轻量查询投影、接入更多编译器语料，并将机制扩展到更大基座与和其他模型结构。

参考文献

- [1] HU E J, SHEN Y, WALLIS P, et al. LoRA: low-rank adaptation of large language models[C]//Proceedings of the 10th International Conference on Learning Representations (ICLR 2022). 2022.
- [2] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems 33 (NeurIPS 2020). 2020: 9459-9474.
- [3] WU Y, RABBAT M, SCHUSTER M, et al. Memorizing transformers[C]//Proceedings of the 10th International Conference on Learning Representations (ICLR 2022). 2022.
- [4] SU J, LU Y, PAN S, et al. RoFormer: enhanced transformer with rotary position embedding[J]. Neurocomputing, 2024, 568: 127063.
- [5] DEEPSEEK-AI. DeepSeek-V4-Flash: technical report[EB/OL]. (2026) [2026年9月5日]. <https://api-docs.deepseek.com/>.
- [6] QWEN TEAM. Qwen3 technical report[EB/OL]. (2025-05-15) [2026年9月5日]. <https://arxiv.org/abs/2505.09388>.
- [7] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30 (NeurIPS 2017). 2017: 5998-6008.
- [8] WOLF T, DEBUT L, SANH V, et al. Transformers: state-of-the-art natural language processing[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2020: 38-45.
- [9] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems 33 (NeurIPS 2020). 2020: 1877-1901.
- [10] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on

Empirical Methods in Natural Language Processing (EMNLP 2021). 2021: 3045–3059.

[11] BORGEAUD S, MENTCH A, KREUZER D, et al. Improving language models by retrieving from trillions of tokens[C]//Proceedings of the 39th International Conference on Machine Learning (ICML 2022). 2022: 2206–2240.

[12] QWEN TEAM. Qwen3.8-27B model card[EB/OL]. (2026-08-14)[2026-09-04]. <https://huggingface.co/Qwen/Qwen3.8-27B>.

[13] DFlash: block diffusion for flash speculative decoding[EB/OL]. arXiv:2602.06036, 2026.

[14] YANG S, ZHANG B, SHEN Y, et al. Gated delta networks: improving Mamba2 with delta rule[EB/OL]. arXiv:2412.06464, 2024.

数据与复现：实验逐题数据见 H:\deepseek\pilot\results\ (pilot1.json / iter2b.json / retrievall.json) ； 复 现 ：
\$env:PYTHONPATH='H:\deepseek\pyext'; python
H:\deepseek\pilot\run_arms3.py --tag iter2b